



셋째마당

딥러닝의 시작, 신경망

9장 오차 역전파에서 딥러닝으로

- 1 딥러닝의 태동, 오차 역전파
- 2 기울기 소실 문제와 활성화 함수
- 3 속도와 정확도 문제를 해결하는 고급 경사 하강법

1 딥러닝의 태동, 오차 역전파


1 딥러닝의 태동, 오차 역전파

● 딥러닝의 태동, 오차 역전파


- 오차 역전파 방법은 어떻게 해서 숨겨진 은닉층의 가중치를 업데이트할 수 있었을까?
- 이를 설명하기 위해 다시 경사 하강법 이야기로 돌아가 보자
- 경사 하강법은 임의의 가중치를 선언하고 결괏값을 이용해 오차를 구한 후 이 오차가 최소인 지점으로 계속해서 조금씩 이동시키는 것
- 이 오차가 최소인 지점은 미분했을 때 기울기가 0이 되는 지점이라고 했음
- 지금 이야기하고 있는 경사 하강법은 ‘단일 퍼셉트론’, 즉 입력층과 출력층만 존재할 때 가능
- 은닉층이 생기면서 우리는 두 번의 경사 하강법을 실행

1 딥러닝의 태동, 오차 역전파

▼ 그림 9-1 | 단일 퍼셉트론에서 오차 수정




▼ 그림 9-2 | 다층 퍼셉트론에서 오차 수정



1 딥러닝의 태동, 오차 역전파

▼ 그림 9-3 | 오차 역전파의 개념



1 딥러닝의 태동, 오차 역전파

● 딥러닝의 태동, 오차 역전파

- 예를 들어 첫 번째 가중치 중 하나인 w_{31} 을 업데이트한다고 하자
- 경사 하강법에서 배운 대로 w_{31} 을 업데이트하기 위해서는 오차 공식을 구하고 w_{31} 에 대해 편미분해야 함
- 합성 함수의 미분이므로 체인 룰을 적용해 편미분을 구하고 이를 이용해 w_{31} 을 업데이트
- 이제 두 번째 가중치를 업데이트할 차례
- 예를 들어 w_{11} 을 업데이트한다고 하면 마찬가지로 오차 공식을 구하고 w_{11} 에 대해 편미분하면 되는데 여기서 문제가 생김
- 앞서 우리는 출력층의 결과와 실제 값을 비교해 오차를 얻었음
- 은닉층은 겉으로 드러나지 않으므로 그 값을 알 수 없음
- 오차를 구할 만한 적절한 출력 값도 없다는 것

1 딥러닝의 태동, 오차 역전파

● 딥러닝의 태동, 오차 역전파

- 이 문제는 다시 출력층의 오차를 이용하는 것으로 해결
- w_{31} 의 경우 y_{o1} 의 오차만 필요했었지만, w_{11} 은 y_{o1} 과 y_{o2} 가 모두 관여되어 있음
- 오차 두 개를 모두 계산해 이를 편미분하게 되는데 물론 계산식은 조금 더 복잡해짐

$$\text{첫 번째 가중치 업데이트 공식} = (y_{o1} - y_{\text{실제 값}}) \cdot \underline{y_{o1}(1-y_{o1})} \cdot y_{h1}$$

$$\text{두 번째 가중치 업데이트 공식} = (\delta y_{o1} \cdot w_{31} + \delta y_{o2} \cdot w_{41}) \underline{y_{h1}(1-y_{h1})} \cdot x_1$$

- 이 공식 중 밑줄 친 부분을 잘 보면 두 식 모두 'out(1-out)' 형태를 취하고 있다는 것을 알 수 있는데 이를 델타식이라고 함
- 은닉층의 숫자가 늘어도 이러한 형태가 계속해서 나타나게 되므로, 이를 이용해 깊은 층의 계산도 할 수 있게 됨
- 이렇게 깊은 층을 통해 학습할 수 있는 계기가 마련되면서 드디어 딥러닝이 태동하게 된 것


2 기울기 소실 문제와 활성화 함수

2 기울기 소실 문제와 활성화 함수

● 기울기 소실 문제와 활성화 함수

- 앞서 델타식을 이용해 깊은 신경망의 계산이 가능해졌음을 이야기했음
- 이제 수많은 층을 연결해 학습하면 여러 난제를 해결하는 인공지능이 완성될 것 같아 보이지만 아직 한 가지 문제가 더 남아 있음

▼ 그림 9-4 | 기울기 소실 문제 발생




2 기울기 소실 문제와 활성화 함수

● 기울기 소실 문제와 활성화 함수

- 그림 9-4와 같이 깊은 층을 만들어 보니 출력층에서 시작된 가중치 업데이트가 처음 층까지 전달되지 않는 현상이 생기는 문제가 발견
- 이는 활성화 함수로 사용된 시그모이드 함수의 특성 때문임
- 그림 9-5와 같이 시그모이드 함수를 미분하면 최대치는 0.25
- 1보다 작으므로 계속 곱하다 보면 0에 가까워짐
- 여러 층을 거칠수록 기울기가 사라져 가중치를 수정하기 어려워지는 것

▼ 그림 9-5 | 시그모이드의 미분




2 기울기 소실 문제와 활성화 함수

● 기울기 소실 문제와 활성화 함수

- 이를 해결하고자 제프리 힌튼 교수는 렐루(ReLU)라는 새로운 활성화 함수를 제안

▼ 그림 9-6 | 여러 활성화 함수의 도입



3 속도와 정확도 문제를 해결하는 고급 경사 하강법

3 속도와 정확도 문제를 해결하는 고급 경사 하강법

- 속도와 정확도 문제를 해결하는 고급 경사 하강법


- 우리는 가중치를 업데이트하는 방법으로 경사 하강법을 배웠음
- 경사 하강법은 정확하게 가중치를 찾아가지만, 계산량이 매우 많다는 단점이 있음
- 이러한 점을 보완한 고급 경사 하강법이 등장하면서 딥러닝의 발전 속도는 더 빨라졌음

- 확률적 경사 하강법


- 경사 하강법은 한 번 업데이트할 때마다 전체 데이터를 미분하므로 속도가 느릴 뿐 아니라, 최적 해를 찾기 전에 최적화 과정이 멈출 수도 있음
- 확률적 경사 하강법(Stochastic Gradient Descent, SGD)은 경사 하강법의 이러한 단점을 보완한 방법
- 전체 데이터를 사용하는 것이 아니라, 랜덤하게 추출한 일부 데이터만 사용하기 때문에 빠르고 더 자주 업데이트할 수 있다는 장점이 있음

3 속도와 정확도 문제를 해결하는 고급 경사 하강법

▼ 그림 9-7 | 경사 하강법과 확률적 경사 하강법의 비교



경사 하강법



확률적 경사 하강법

3 속도와 정확도 문제를 해결하는 고급 경사 하강법


- 속도와 정확도 문제를 해결하는 고급 경사 하강법

- 모멘텀


- 모멘텀(momentum)이란 단어는 ‘관성, 탄력, 가속도’라는 뜻
 - 모멘텀 확률적 경사 하강법(모멘텀 SGD)이란 말 그대로 경사 하강법에 탄력을 더해 주는 것
 - 다시 말해 경사 하강법과 마찬가지로 매번 기울기를 구하지만, 이를 통해 오차를 수정하기 전 바로 앞 수정 값과 방향(+, -)을 참고해 같은 방향으로 일정한 비율만 수정되게 하는 방법
 - 수정 방향이 양수(+) 방향으로 한 번, 음수(-) 방향으로 한 번 지그재그로 일어나는 현상이 줄어들고, 이전 이동 값을 고려해 일정 비율만큼 다음 값을 결정하므로 관성 효과를 낼 수 있음

3 속도와 정확도 문제를 해결하는 고급 경사 하강법

▼ 그림 9-8 | 모멘텀을 적용했을 때



확률적 경사 하강법



모멘텀을 적용한 확률적 경사 하강법

3 속도와 정확도 문제를 해결하는 고급 경사 하강법

● 속도와 정확도 문제를 해결하는 고급 경사 하강법

- 이 밖에도 딥러닝의 학습을 더 빠르고 정확하게 만들기 위한 노력이 계속됨
- 지금은 정확도와 속도를 모두 향상시킨 아담(adam)이라는 고급 경사 하강법이 가장 많이 쓰이고 있음

▼ 그림 9-9 | 딥러닝에 사용되는 고급 경사 하강법의 변천

